

# Filtragem como pré-processamento de CGAN na detecção de glaucoma

Erick Aparecido Escagion, José Eduardo Saroba Bieco, Gabriel Fré e Tales Carvalho

**Resumo**— Este trabalho propõe o uso de pré-processamento de imagens médicas para melhorar o desvio padrão da acurácia de métodos de diagnósticos de retinopatias baseados em aprendizado de máquina. Para tanto, são utilizados resultados obtidos à partir de redes neurais geradoras adversárias condicionadas para segmentação da retina, sobre os quais são aplicados os métodos de filtragem, resultando na diminuição do desvio padrão da acurácia na identificação de estruturas da retina, que podem contribuir na detecção de retinopatias, tais como DMRI (Degeneração Macular Relacionada a Idade) e hiposfagma. Este trabalho apresenta uma melhoria no desvio padrão da acurácia de 11,11% para a métrica DSC, e de 18,18% para a métrica IoU.

**Palavras-Chave**— Aprimoramento de imagem, Redes Neurais Convolucionais, Retinopatia, Imagens médicas.

**Abstract**— This work proposes the use of medical image pre-processing to improve the accuracy standard deviation of machine learning-based diagnostic methods for retinopathies. For this purpose, results obtained from adversarial generative neural networks conditioned for the task of retinal segmentation are used, on which the proposed filtering methods are applied in order to observe the decrease in the standard deviation of accuracy in the identification of retinal structures. retina, such as aspects of the optic nerve, veins and arteries, as well as investigations into other retinopathies, such as AMD (Age-Related Macular Degeneration) and hyposphagma. Showing an improvement in the accuracy standard deviation of 11.11% for the DSC neural network, and 18.18% for the IoU network.

**Keywords**— Image enhancement, Convolutional Neural Networks, Retinopathy, medical images.

## I. INTRODUÇÃO

Glaucoma é uma condição que acomete cerca de 1 a 2% na população geral e pode causar cegueira irreversível quando não tratada a partir de seu estágio inicial, segundo o CBO (Conselho Brasileiro de Oftalmologia) [1]. Este trabalho propõe um esquema de pré-processamento de imagens a fim de otimizar processos de aprendizado de máquina para detecção precoce desta e outras retinopatias.

O processamento de imagens e aplicações de visão computacional têm sido amplamente utilizados em análises de imagens médicas levando a melhorias significativa na qualidade de radiografias, tomografias e ressonâncias magnéticas. Tais métodos permitem a remoção de ruídos e artefatos que podem dificultar ou inviabilizar diagnósticos e triagens [2]. Neste trabalho são utilizados processos de filtragem sobre retinografias, de modo similar ao que é apresentado por Divya et. al [3].

Erick Aparecido Escagion (ericeescagion@gmail.com), José Eduardo Saroba Bieco (josebieco@gmail.com) e Gabriel Fré (gabriel.vasconcelos@facens.br) são vinculados ao Centro Universitário Facens. Tales Carvalho (taleshen@ualberta.ca) é vinculado ao Department of Computing Science da University of Alberta.

Contudo, neste caso, o objetivo é realçar bordas e detalhes que possam melhorar a detecção de estruturas da retina pelo uso de CGAN (Redes Adversárias Generativas Condicionadas), a qual é utilizada na geração de dados condicionada [4]. Os resultados obtidos pelo desenvolvimento deste trabalho contribuem significativamente na diminuição da variância de um método para detecção de glaucoma demonstrado por Carvalho et. al [4].

## II. TRABALHOS CORRELATOS

O diagnóstico de glaucoma envolve o cálculo da escavação do nervo óptico por meio de visão computacional [5], obtidos pelo modelo gerativo utilizado por Carvalho et. al [4]. A condição de glaucoma é constatada quando a relação entre a escavação óptica e o disco óptico resulta em valores superiores a 0,5 [5]. O trabalho em questão apresenta acurácia comparável aos modelos do estado-da-arte, tal como o U-Net, com 0,94 [6], e o DR-GAN demonstrando 0,95 [7].

## III. DESENVOLVIMENTO

O algoritmo proposto neste trabalho está desenvolvido em Python3 e baseado em estruturas de filtros disponíveis na biblioteca de códigos abertos para visão computacional e aprendizado de máquina denominada OpenCV (*Open Source Computer Vision Library*). Foram aplicados filtros GaussianBlur e addWeighted para realizar o pré-processamento da imagem base. Para o GaussianBlur, utilizaram-se os parâmetros (img, (0, 0), 15). Nesse caso, *img* representa a imagem base a ser processada, enquanto (0, 0) se refere ao parâmetro *ksize*, que indica o tamanho do Kernel Gaussiano. O desvio padrão do kernel, *sigmaX* = 15 é definido ao longo do eixo *x*. Para o addWeighted, empregaram-se os parâmetros (img, 4, GaussianBlur, -4, 128), em que *img* representa a imagem base com *alpha* = 4 e *beta* = -4. GaussianBlur é a imagem resultante após a aplicação do filtro com *gamma* = 128. Partindo-se da hipótese de que estes filtros, quando devidamente configurados, aumentam a acurácia na detecção de veias na retina, o pré-processamento obtido por estes filtros resulta na padronização das imagens, conforme visto na Figura 1.(c). A coloração das veias é ressaltada pela redução da saturação dos canais RGB (*Red-Green-Blue*), respectivamente de 0–255, para 0–130, 0–100 e 0–140, valores esses que foram escolhidos após as imagens passarem pela pré filtragem, pois representam a coloração dos pixels das veias.

O processo de detecção consiste em registrar os pixels que representam as veias, conforme a Fig. 1.(d). Ao final, tem-se na Fig. 1.(e), a sobreposição destas veias sobre a imagem original, Fig. 1.(a), na cor branca.

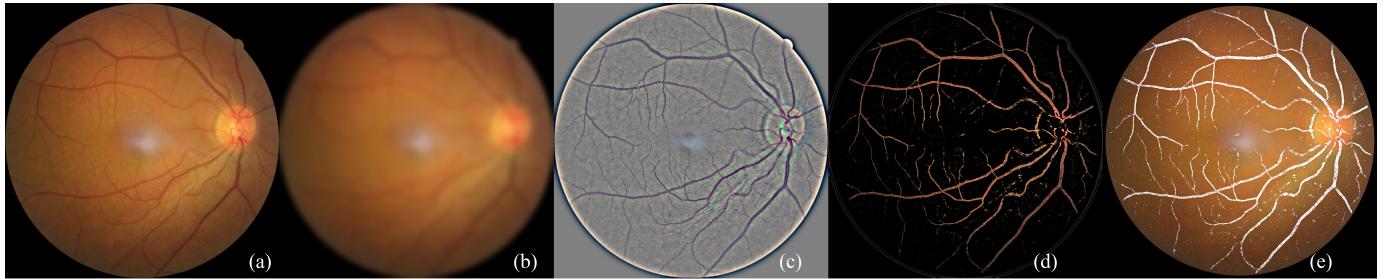


Fig. 1. Ciclo de pré-processamento da retinografia. (a) Aquisição da imagem. (b) Aplicação do *GaussianBlur*. (c) Aplicação de *addWeighted*. (d) Imagem resultante contendo pixels definidos como vasos e veias. (e) Imagem resultante com veias em destaque.

As imagens pré-processadas são utilizadas para o treinamento da rede, e o principal resultado é obtido ao se comparar o desempenho da rede quando treinadas pelas mesmas imagens sem qualquer pré-processamento. São observadas melhorias significativas nos desvios padrões das métricas *DSC* (Coeficiente Dice de Similaridade) e *IoU* (Interseção sobre União) utilizadas nos modelos de localização de disco (M-LD) e de segmentação de retina (M-SR) [4]. Os resultados indicaram um aumento de 11,11% na métrica *DSC*, evoluindo de 0,09% para 0,08%, e um incremento de 18,18% na métrica *IoU*, com variação de 0,011% para 0,09%, como se verifica na Tabela I. Todavia, as acuráncias das redes não sofreram variações significativas. Ademais, verifica-se na Fig. 2, que a cor vermelha teve um aumento considerável nos pixels com maior saturação, já as cores verdes, azuis e vermelha tiveram uma acentuação nos canais de baixas e médias saturações.

TABELA I  
COMPARAÇÃO DA REDE CGAN COM E SEM O FILTRO

Rede Neural	M-LD		M-SR	
	IoU	Std	DSC	Std
CGAN	0.93	0.09	0.84	0.11
CGAN + Filtro	0.93	0.08	0.84	0.09

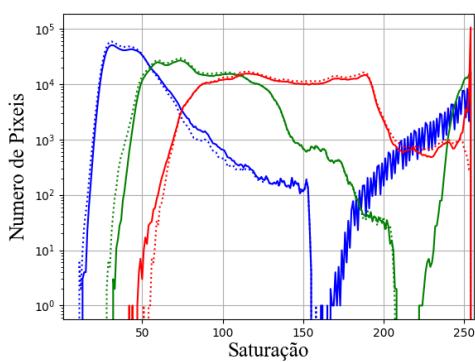


Fig. 2. Histograma contendo imagem original (linhas pontilhadas) e imagem processada (linhas contínuas).

#### IV. CONCLUSÕES

Após a análise dos resultados da CGAN, com e sem a aplicação do filtro desenvolvido, constatou-se que a filtragem proposta contribui para a redução do desvio padrão da rede neural proposta por Carvalho et al. [4], resultando em um

modelo mais confiável, uma vez que designa uma menor probabilidade de classificação do diagnóstico fora das expectativas matemáticas. Além disso, a filtragem proposta não comprometeu a acurácia do modelo. É importante destacar que, até o momento, não foram encontrados trabalhos correlatos na literatura que explorem o uso do filtro Gaussiano em redes CGAN para a detecção de glaucoma. Portanto, essa utilização se configura como uma inovação no campo de diagnóstico oftalmológico.

Esses resultados promissores indicam que o filtro Gaussiano pode desempenhar um papel crucial na melhoria da aplicabilidade da CGAN no diagnóstico de glaucoma, abrindo novas possibilidades para pesquisas futuras em outras áreas médicas que também possam se beneficiar dessa técnica.

#### AGRADECIMENTOS

Os Autores agradecem ao Centro Universitário Facens a o *Department of Computing Science da University of Alberta* pelo apoio a esta pesquisa.

#### REFERÊNCIAS

- [1] J. Ottaiano, M. de Ávila, C. Umbelino, and A. Taleb, “Cegueira e baixa visão no adulto,” *As condições de saúde ocular no Brasil. São Paulo: Conselho Brasileiro de Oftalmologia*, pp. 24–30, 2019.
- [2] A. K. Jain, *Fundamentals of digital image processing*. Prentice-Hall, Inc., 1989.
- [3] S. Divya, K. Raja, S. Priya, S. Nagarajan, and S. Palanivel, “Automated detection of diabetic retinopathy using histogram thresholding and morphological processing,” *Journal of Medical Imaging and Health Informatics*, vol. 9, no. 7, pp. 1368–1374, 2019.
- [4] T. H. Carvalho, C. H. Moraes, R. C. Almeida, and D. H. Spadoti, “Application of conditional gan models in optic disc/optic cup segmentation of retinal fundus images,” in *17th International Symposium on Medical Information Processing and Analysis*, vol. 12088, pp. 1–7, SPIE, 2021.
- [5] C. Bowd, L. M. Zangwill, P. A. Berry, and R. N. Weinreb, “Detecting early glaucoma by assessment of retinal nerve fiber layer thickness and visual function,” *Investigative ophthalmology & visual science*, vol. 42, no. 9, pp. 1993–2003, 2001.
- [6] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pp. 234–241, Springer, 2015.
- [7] Y. Peng, Y. Liu, H. Jiang, and H. Fu, “Dual-refinement gan for high-resolution image synthesis and editing,” in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 8074–8083, IEEE, 2019.

#### APÊNDICE

O código fonte do algoritmo desenvolvido está disponível em <https://github.com/ErickEscagion/SBRT2023>